

Entrega parcial 2 Modelos de classificação e explicabilidade

TCC: Protótipo Híbrido para Detecção e Explicação de Fraudes em Transações Pix Simuladas Utilizando Machine Learning, SHAP e RAG

Autores: Letícia Alves (ML e dados) · Lucas Nogueira (RAG e escrita)

Data da consolidação: 20 de setembro de 2026

Sobre os dados: este trabalho não utiliza dados reais do Pix nem de instituições financeiras. Os experimentos usam o dataset público IEEE-CIS Fraud Detection (Kaggle), de transações com cartão. As variáveis inspiradas no Pix são proxies analíticos documentados, conforme a seção 4.1 da proposta aprovada.

1. O que esta entrega cobre

Os dois modelos previstos na proposta - **XGBoost** como principal e **Random Forest** como comparativo - treinados sobre as mesmas 590.540 transações, com o mesmo pré-processamento e o mesmo corte temporal do baseline de junho, e a aplicação do **SHAP** sobre o modelo escolhido.

Todos os modelos usam o mesmo tratamento de desbalanceamento (ponderação de classe, adotada em junho) e são medidos pelo mesmo código, `src/models/evaluator.py`. Isso é o que permite atribuir as diferenças ao algoritmo, e não à forma de medir.

O artefato XGBoost entregue, que também produziu o relatório SHAP, alcançou AUC-PR 0,5719 na validação e 0,4833 no teste. A avaliação final reutilizou o modelo e o pré-processador persistidos. O limiar 0,6834220290 foi escolhido por maximização de F1 exclusivamente na validação, antes de medir o teste.

2. Comparação entre modelos - validação

Conjunto de validação: 88.581 transações, 3.042 fraudes, taxa base 3,434%. A AUC-PR de um classificador aleatório equivale à taxa base, e é a régua de leitura.

Modelo	AUC-PR	AUC-ROC	Tempo de treino
Regressão logística (baseline de junho)	0,3930	0,8410	6 min
Random Forest, profundidade ≤ 20	0,4573	0,8751	140 s
XGBoost, hiperparâmetros padrão	0,5293	0,9044	56 s
Random Forest, árvores completas	0,5298	0,9078	176 s
XGBoost entregue e usado no SHAP	0,5719	0,9067	Não medido separadamente ¹

¹ Os 30 s registrados anteriormente pertencem ao retreino histórico do tuning, não à geração deste artefato. A busca histórica com 50 tentativas levou 829 s; o fluxo completo levou 902 s e atingiu pico de 5.266 MB. Não se atribui esse tempo ao artefato atual.

O resultado 0,5703 permanece como evidência histórica em `reports/tuning_xgboost.json`. O modelo reconstruído com os parâmetros selecionados para compatibilidade com SHAP obteve 0,5719 e passou a ser o artefato entregue. A tabela identifica essa execução; os números históricos não foram apagados nem reinterpretados como novas medições.

Dois pontos que a tabela já sustenta:

O **Random Forest empata com o XGBoost sem ajuste** (0,5298 contra 0,5293). Não cabe afirmar superioridade genérica do modelo principal sobre o comparativo; o que a evidência mostra é que a diferença, se existir, vem da busca de hiperparâmetros.

Ambos superam o baseline com folga, o que justifica a complexidade adicional em relação a um modelo linear - o critério que havíamos declarado para esta etapa.

3. Metodologia da busca de hiperparâmetros

Seis decisões, registradas em `reports/anotacoes_metodologia.md`:

- 1 **A métrica otimizada é a AUC-PR na validação.** Otimizar AUC-ROC premiaria ordenar bem os 96,5% de casos fáceis; acurácia premiaria não detectar nada.
- 2 **O parâmetro de desbalanceamento não entra na busca.** Fica fixo na razão real entre classes (27,43), que é a forma do XGBoost expressar a ponderação de classe adotada em junho. Deixá-lo variar transformaria uma decisão metodológica já comparada em mais um hiperparâmetro.
- 3 **O pré-processamento é ajustado uma vez, fora da busca.** Não depende dos hiperparâmetros, e é ajustado somente no treino - validação e teste apenas recebem a transformação.
- 4 **O conjunto de teste não é tocado durante a busca.** A seleção acontece na validação; o teste é avaliado uma única vez, ao final, com o modelo já escolhido.
- 5 **A busca usa uma amostra temporal do treino.** Cada tentativa usa as 150 mil transações mais recentes do treino, com a validação completa. O candidato alcançou AUC-PR 0,5912 nessa condição. O artefato entregue, treinado anteriormente no treino completo com os parâmetros selecionados e XGBoost 3.0.5, apresenta AUC-PR 0,5719. O retreino histórico do tuning registrou 0,5703 com XGBoost 3.4.1. São execuções distintas; a avaliação final usa apenas o artefato entregue.
- 6 **O espaço e a poda foram reduzidos por viabilidade.** O teto passou de 600 para 300 árvores e a profundidade máxima de 10 para 8. Um MedianPruner interrompeu 25 das 50 tentativas após aquecimento. A melhor configuração atingiu os dois tetos, portanto não se afirma que seja um ótimo global.

Os melhores parâmetros foram `learning_rate=0,2308`, `max_depth=8`, `min_child_weight=14,5371`, `subsample=0,8712`, `colsample_bytree=0,9159`, `gamma=1,6854`, `reg_alpha=0,1130` e `reg_lambda=1,2327`, com 300 árvores e `scale_pos_weight=27,4343` fixo.

4. Explicabilidade - SHAP

O XGBoost final foi explicado com TreeExplainer, usando `feature_perturbation="interventional"`, saída em escala de probabilidade e um fundo de 500 linhas amostradas exclusivamente do treino (seed 42). A análise global usou 1.000 transações aleatórias da validação.

As cinco variáveis de maior média absoluta de contribuição foram `TransactionAmt`, `C13`, `C1`, `C14` e `card1`. Duas proxies com semântica documentada também aparecem cedo no ranking: `valor_atipico_proxy` em 7º lugar e `frequencia_recente_proxy` em 13º. Esse resultado indica influência no comportamento do modelo; **não prova causalidade** e não revela o significado oculto das colunas anônimas.

Foram produzidos force plots para um verdadeiro positivo, um falso positivo, um falso negativo e um verdadeiro negativo, escolhidos pela probabilidade mediana de cada quadrante. A fidelidade numérica foi verificada em todas as linhas explicadas: o erro máximo em valor base + soma das contribuições = probabilidade prevista foi $3,04 \times 10^{-7}$, abaixo da tolerância 10^{-5} . O relatório, o summary plot e os quatro casos estão em `reports/pessoa_1/julho/shap/`.

Os casos SHAP históricos foram selecionados com limiar 0,5. A escolha posterior do limiar F1 não altera as contribuições, mas pode alterar a classificação de casos locais; por isso, seus rótulos VP, FP, FN e VN não são reapresentados como se tivessem sido calculados com o limiar final.

5. Avaliação final no teste

A avaliação final foi executada em 18/09/2026, sobre as 88.581 transações do período de teste, com 3.083 fraudes (3,4804%). O modelo e o pré-processador foram carregados por `src.models.persistencia.carregar`, com verificação de hashes. Não houve retreino ou novo ajuste de pré-processamento.

Métrica	Validação no limiar F1	Teste com limiar congelado
Limiar	0,6834220290	0,6834220290
AUC-PR (average precision)	0,5719	0,4833
AUC-ROC	0,9067	0,8700
Precisão	0,6680	0,5852

Métrica	Validação no limiar F1	Teste com limiar congelado
Recall	0,4829	0,4324
F1	0,5606	0,4973

Matriz de confusão no teste, com linhas representando a classe real e colunas representando a classificação do modelo:

Classe real	Prevista legítima	Prevista fraude
Legítima	84.553	945
Fraude	1.750	1.333

O modelo sinalizou 2.278 transações e recuperou 1.333 das 3.083 fraudes rotuladas. A AUC-PR caiu aproximadamente 0,0887 entre validação e teste, evidenciando degradação no período posterior. Esses resultados não sustentam desempenho equivalente em Pix real.

Os valores completos, versões, hashes do dataset e hashes do artefato estão em `reports/avaliacao_xgboost_entregue.json`. O limiar foi salvo em `models/xgboost/politica_decisao.json` antes da inferência no teste. O script `scripts/avaliar_xgboost_entregue.py` recusa sobrescrever uma avaliação já registrada.

6. Ressalvas metodológicas

As métricas de decisão não são comparáveis entre modelos no limiar padrão. No corte de 0,5, os modelos operam em pontos muito distintos da curva:

Modelo	Recall	Precisão
Regressão logística	0,68	0,14
XGBoost padrão	0,67	0,27
Random Forest, árvores completas	0,32	0,80

Cada modelo distribui suas probabilidades de forma própria, e o mesmo 0,5 cai em lugares diferentes de cada curva. Comparar precisão, recall ou F1 nesse ponto compara **calibração**, não qualidade. A comparação legítima entre modelos é a AUC-PR, que independe do limiar.

Critério adotado: maximização de F1 na validação. A dupla decidiu usar `criterio="f1"`, pois restrições de precisão mínima ou recall mínimo exigiriam alvos numéricos sem justificativa operacional disponível. A função `escolher_limiar` selecionou 0,6834220290184021; em empate de F1, a implementação escolhe o menor limiar. Essa escolha não usa os rótulos do teste.

O quadro acima preserva os pontos de operação históricos no corte 0,5. Aplicar 0,683422 aos outros modelos não remove diferenças de calibração e não equivale a selecionar F1 para cada modelo. Não foi calculada uma nova comparação nesse corte: os artefatos ou vetores de probabilidades da regressão logística e do Random Forest não estavam disponíveis nesta execução. Essa comparação permanece uma limitação explícita; a comparação principal da seção 2 usa AUC-PR, independente de limiar.

Profundidade no Random Forest. Com árvores completas, a floresta chega a profundidade média 64 e 16.430 folhas por árvore - memorização de transações individuais. Limitar a profundidade a 20 reduz o custo, mas **custa 0,07 de AUC-PR** (0,4573 contra 0,5298). A capacidade extra é aproveitada pela média das 100 árvores, e por isso foi mantida.

Uma medição preliminar com 10 árvores havia indicado empate entre as duas configurações. A conclusão não se sustentou com 100: extrapolação linear vale para custo, não para qualidade.

7. Limitações assumidas

- **O dataset é de cartão, não de Pix** - nenhum resultado indica desempenho no Pix real.
- **Três variáveis da proposta não têm equivalente no IEEE-CIS:** tipo de chave Pix, perfil do destinatário e idade da conta.

- **O Random Forest não passou por busca de hiperparâmetros**, conforme seu papel de modelo comparativo na proposta. A comparação com o XGBoost ajustado precisa ser lida com essa assimetria em mente.
- **Retreino e carregamento são procedimentos diferentes**: reconstruir árvores pode variar com versões e operações numéricas. Nesta avaliação, carregar o mesmo artefato reproduziu as métricas registradas na validação. O comportamento observado não garante igualdade bit a bit em qualquer ambiente.
- **A busca amostral é uma aproximação**: o candidato na cauda do treino marcou 0,5912. Para a entrega, usa-se 0,5719 do artefato congelado; 0,5703 identifica somente a execução histórica do tuning.
- **A melhor tentativa atingiu os limites do espaço reduzido** (300 árvores e profundidade 8), de modo que a busca não demonstra que esses tetos sejam ótimos globais.
- **Há degradação temporal no XGBoost entregue**: a AUC-PR caiu de 0,5719 na validação para 0,4833 no teste preservado.

8. Próxima etapa

O código de integração das três camadas está integrado ao repositório: recuperador documental, construção de prompt, pipeline e notebook demonstrativo. O índice reconstruído possui proveniência própria. Permanecem pendentes a ativação do cliente LLM, a resolução das entradas do pipeline na interface e a avaliação experimental das explicações; testes com clientes simulados não equivalem a geração real pelo LLM.

9. Ponto para alinhamento

O envio ao orientador deve ser feito pela dupla após a revisão deste documento. A implementação do cliente LLM, o responsável pela chave e o teto mensal de custo exigem decisão operacional conjunta. A presente entrega conclui a medição do modelo principal e a escolha do limiar; não declara a geração RAG ou a comparação de todos os classificadores no limiar final como concluídas.